



Bienvenue sur Sakata

Ce portail est un sanctuaire numérique dédié à la préservation et à la transmission de l'identité culturelle du peuple **Sakata**.



Notre objectif est d'unir nos racines ancestrales avec la splendeur numérique moderne, en offrant à la fois des archives vivantes, des sagesses intemporelles et un forum d'échange intergénérationnel.

Suivant →

Le « Cerveau Sakata » est l'index Pinecone qui agrège toutes les sources de connaissance — livres ethnographiques, articles publiés, forums diaspora, futurs transcripts de Veillée Numérique. Toute production d'article peut s'appuyer sur cette mémoire vectorielle pour suggérer sources et cohérence factuelle.

STACK

Configuration de l'index

ÉLÉMENT	VALEUR
Index name	sakata
Cloud provider	AWS us-east-1 (serverless)
Dimension	768
Métrique	cosine
Modèle d'embedding	intfloat/multilingual-e5-base
Préfixe E5 documents	passage:
Préfixe E5 requêtes	query:
Total vecteurs	1607 (au 2026-04-29)
Chunking	500 mots, overlap 50

POURQUOI 768 ET PAS 3072 ?

multilingual-e5-base (768 dim) est :

- Excellent en multilingue : français, kisakata, lingala, swahili, flamand, latin.
 - 10× plus économique en stockage que text-embedding-3-large .
 - Open source — pas de dépendance OpenAI pour l'indexation initiale.
 - Suffisant en qualité pour le corpus Sakata (validé sur 1500+ chunks).
- Migrer vers 3072 dim plus tard est possible mais coûterait : re-embed total + Pinecone plus cher.

STRUCTURE

Organisation par namespaces

NAMESPACE	VECTEURS	CONTENU
<code>__default__</code>	1554	Sources externes brutes : PDFs académiques, OCR de scans
<code>sakata</code>	43	Articles publiés sur sakata-basakata.com (chunks)
<code>iluo_livres_site</code>	9	Mini-livres internes (Mboka, Origines, Épopée)
<code>iluo_forums</code>	1	Posts Facebook scrappés (test initial validé)

POURQUOI DES NAMESPACES ET PAS UN METADATA FIELD ?

Les namespaces Pinecone offrent : isolation des index, query par namespace natif, possibilité future de facturation/quotas séparés, et migration plus simple si on veut sortir une catégorie.

Sources déjà indexées (livres)

LIVRE	STATUT
The Sakata Society in the Congo — Roger Vanzila Muni	✔ Référence ethnographique majeure
L'Évangélisation du Mai-Ndombe — Mpia Bekina (2009)	✔ Thèse philosophie/théologie
Religie en magie onder de Basakata — Van Everbroeck (1952, flamand)	✔ Religion et magie chez les Basakata
Sakata profil DICE	✔ Dictionary of Indigenous Cultural Expressions
Formation Récentes de Sociétés Secrètes au Congo Belge	✔ OCR manuel ingéré
MEPST programmes scolaires (3e/4e/5e Sec MATH + PE7/PE8 + Primaire)	✔ Curriculum officiel RDC
Phonologie de la langue sakata — Thèse 1987	● PDF scanné, OCR à faire
Formations Récentes de sociétés secrètes (PDF scanné)	● PDF scanné, OCR à faire

SCRIPTS

Pipeline d'ingestion

Scripts disponibles

- `scripts/ingest_books_smart.py` — Détecte les sources déjà indexées et n'ingère que les manquantes (idempotent)
- `scripts/vectorize_sakata.py` — Pipeline initial complet (réindexation totale)
- `scripts/batch_index_articles.py` — Articles publiés vers namespace `sakata`
- `scripts/batch_index_forum.py` — Forum/Facebook vers namespace `iluo_forums`
- `scripts/batch_index_pages.py` — Pages internes vers `iluo_livres_site`
- `scripts/pinecone_stats.mjs` — Stats live de l'index
- `scripts/pinecone_inspect.mjs` — Échantillonnage par namespace pour voir le contenu

Format de chunks

CODE

PYTHON

```
{
  "id": f"{filename}__p{page}__c{chunk_index}", # ASCII-safe
  "values": [ ... ] # 768-dim embedding (passage: prefix)
  "metadata": {
    "source": "filename.pdf",
    "directory": "Folder Name",
    "page": 42,
    "chunk_index": 0,
    "text": "...first 1000 chars for retrieval display...",
  }
}
```

3 FOURNISSEURS

Pipeline OCR pour PDFs scannés

POURQUOI 3 SCRIPTS OCR ?

Chaque fournisseur IA a un blocage différent sur les vieux textes ethnographiques. Avoir les 3 permet de basculer sans refactor.

SCRIPT	MODÈLE	COÛT (200 PAGES)	LIMITATION
ocr_pdf_gemini.py	gemini-2.5-pro	~\$0.02	FinishReason.RECITATION sur académique
ocr_pdf_claude.py	claude-haiku-4-5	~\$0.30	Pas de blocage, requiert crédit
ocr_pdf_openai.py	gpt-4o-mini	~\$0.14	Quota dépendant du tier

Format de sortie unifié

```
# OCR via <model>
# Source: <filename>.pdf

--- PAGE 1 ---

[texte transcrit fidèlement]

--- PAGE 2 ---

[texte transcrit fidèlement]

...

```

Le fichier `.ocr.txt` est ensuite ingéré automatiquement par `ingest_books_smart.py` (détection du format `--- PAGE N ---`).

Reprise (resume) automatique

Si l'OCR plante (rate limit, crédit), relancer la même commande reprend là où ça s'était arrêté. Le script lit le fichier .ocr.txt existant, identifie les pages déjà OCR'd via les markers `--- PAGE N ---`, et continue.

RAG

Plan d'utilisation runtime

Recherche sémantique côté public

CODE

TYPESCRIPT

```
// Côté API : /api/articles/search
// Le user tape "rituel d'initiation"
// → embed avec prefix "query:"
// → query Pinecone namespace 'sakata' (articles publiés)
// → ranger par score, retourner top 10

import { getPineconeIndex } from "@lib/pinecone/client";

const index = getPineconeIndex();
const results = await index
  .namespace("sakata")
  .query({
    vector: queryEmbedding,
    topK: 10,
    includeMetadata: true,
    filter: { lang: "fr" }, // optional metadata filter
  });
```

Assistance rédaction côté admin

Dans l'éditeur d'article, à chaque sauvegarde du brouillon :

1. Embed du brouillon (prefix `query:`).
2. Query `__default__` namespace (livres académiques).
3. Top 5 chunks affichés en panneau latéral comme « Sources liées ».
4. Bouton « Citer » insère le passage avec citation source/page.

ROADMAP

Extension future

- **Scraping Facebook en masse** via Playwright (groupes diaspora) → namespace `iluo_forums`.
- **Veillée Numérique** : transcripts Whisper → namespace dédié `veillees`.
- **Notes admin** : indexation des notes personnelles comme contexte privé pour l'auteur.
- **Cross-référencement automatique** : à chaque publication d'article, suggérer 3 articles existants liés sémantiquement.
- **Migration vers 3072 dim** : si la qualité 768 devient limitante (probablement pas avant 10k+ chunks).

BONNES PRATIQUES

Sécurité & confidentialité

- Clé Pinecone (`PINECONE_API_KEY`) jamais exposée côté client.
- Tous les appels embed/query passent par des API routes Next.js avec auth.
- Le namespace `__default__` contient des œuvres sous copyright — usage interne uniquement (pas de re-publication verbatim).
- Quand un chunk est cité publiquement, toujours afficher source + page + auteur.
- Sensibilité culturelle : les textes ethnographiques coloniaux contiennent parfois des biais — le prompt système des assistants IA doit explicitement reformuler en respectant la dignité Sakata.

Sakata.com — Documentation interne · architecture-pinecone-corpus · v2026.4

« Moto oyo ayebi te kotombola miso na likolo, akoki te koyeba esika oyo mbula eutaka. » — Proverbe Sakata

SAKATA

© 2026 — Brume de la Rivière. Tous droits réservés.

CULTURE

ECOLE

LANGUE

HISTOIRE

FORUM