FR

Bienvenue sur Sakata

Ce portail est un sanctuaire numérique dédié à la préservation et à la transmission de l'identité culturelle du peuple **Sakata**.

Notre objectif est d'unir nos racines ancestrales avec la splendeur numérique moderne, en offrant à la fois des archives vivantes, des sagesses intemporelles et un forum d'échange intergénérationnel.

Suivant →

> *Sakata.com utilise trois fournisseurs d'IA : Anthropic (Claude), Google (Gemini), OpenAI. Pas par mode mais par stratégie. Chaque modèle a ses forces, ses faiblesses, et son prix. Le routage intelligent peut diviser les coûts par trois sans perdre en qualité.*

DÉCISION

Pourquoi pas tout sur un seul ?

CHOIX

Routage multi-providers, pas de monoculture IA.

- **Robustesse** : si Anthropic a un outage, Sakata continue de fonctionner sur Gemini.
- **Spécialisation** : Gemini est meilleur sur les langues bantu, Claude sur la voix narrative, GPT sur le tooling structuré.
- **Coût** : faire tourner Claude Opus 4 pour traduire un titre de 5 mots = gaspillage. Gemini Flash le fait pour 1/100e du prix.
- **Pas de vendor lock** : si un provider change ses prix de 10×, on peut migrer en 1 jour.

STRATÉGIE

Matrice de routage

TÂCHE	MODÈLE RETENU	RAISON
Voix narrative ancestrale (sage-basakata)	Claude Sonnet 4.5	Ton et nuance supérieurs
Traduction multilingue (FR ↔ langues bantu)	Gemini 1.5 Pro	Couverture africaine supérieure
Synthèse vocale (TTS)	Gemini Voice	Qualité voix + multilingue natif
Chat sémantique encyclopédie	Gemini 1.5 Pro	Contexte long, RAG-friendly
Tagging / structuration JSON	Gemini 1.5 Flash	10× moins cher, JSON output fiable
Embedding pour Pinecone	OpenAI text-embedding-3-large	Meilleur état de l'art
Transcription audio (futur Veillée)	Whisper API (OpenAI)	Standard de marché
Modération automatique	Claude Haiku 4.5	Petit, rapide, raisonnable

CONFIGURATION

Variables d'environnement

.ENV.LOCAL

```
# Routage par défaut (override possible par tâche)
LLM_PROVIDER=claude

# API keys (rotables)
ANTHROPIC_API_KEY=sk-ant-...
GEMINI_API_KEY=AI...
OPENAI_API_KEY=sk-proj-...
ALIBABA_QWEN_API_KEY=sk-...     # Backup futur

# Limites de sécurité
AI_MAX_TOKENS_PER_USER_DAY=50000
AI_MAX_COST_PER_USER_MONTH_USD=2
```

CODE

Pattern d'appel typique

CODE TYPESCRIPT

```typescript
// src/lib/ai/route.ts (simplifié)
async function callLLM({
  task,             // "translate" | "narrate" | "tag" | ...
  prompt,
  context,
  userId,
}: LLMRequest) {

  // 1. Vérifier les quotas
  await assertWithinQuota(userId);

  // 2. Choisir le provider
  const provider = ROUTING_TABLE[task];

  // 3. Logger l'activité (audit + analytics)
  await logActivity(userId, "ai_call", {
    task,
    provider,
    timestamp: Date.now(),
  });

  // 4. Appeler avec retry & fallback
  try {
    return await provider.call({ prompt, context });
  } catch (err) {
    if (err.code === "RATE_LIMIT") {
      return await FALLBACK_PROVIDER[task].call({ prompt, context });
    }
    throw err;
  }
}
```

BUDGET

Coûts mensuels actuels (estimation)

PROVIDER	VOLUME MENSUEL ACTUEL	COÛT USD
Anthropic (Claude Sonnet)	~50k tokens output	~3$
Gemini 1.5 Pro	~200k tokens	~5$
Gemini Voice	~30 articles narrés × 1500 chars	~2$
OpenAI (embeddings)	~50 articles vectorisés	~0.5$
Total estimé	—	≈ 10-12 $/mois

PROJECTION À 1 000 ARTICLES + 500 VEILLÉES/MOIS

Coût projeté : **≈ 150 $/mois**. Reste largement amortissable avec 30 abonnés Premium.

OBSERVABILITÉ

Activity logging structuré

Chaque appel IA est loggé dans la table `activity_log` avec metadata typée (provider, task, tokens, latency, cost). Permet :

- Audit des coûts par utilisateur, par feature.
- Détection d'abus (un user qui consomme 10× la moyenne).
- Analyse de qualité (corrélation user-rating ↔ provider).
- Optimisation A/B : tester deux providers sur la même tâche.

RETOUR D'EXPÉRIENCE

Difficultés rencontrées

JSON output fragile sur Claude

Claude est excellent en prose mais parfois capricieux quand on lui demande du JSON strict. Solution : passer à Gemini 1.5 Pro qui supporte le mode `responseSchema` natif (garantie de validité).

Coûts qui dérapent silencieusement

Un test mal écrit peut faire 1 000 appels Claude Opus en boucle. Mitigation : quota strict côté serveur (par user et par jour) qui retourne 429 si dépassé.

Latence Gemini sur grandes contextes

Gemini 1.5 Pro avec 100k tokens en input prend 30+ secondes. Pour l'expérience interactive, on découpe en chunks ou on streame.

À SAVOIR

Limitations connues

- Pas de fine-tuning maison (kisakata pourrait en bénéficier).
- Pas encore de A/B testing automatisé sur les providers.
- Pas de cache cross-user (deux users qui demandent la même chose paient deux fois).

Sakata.com — Documentation interne · feature-ai-orchestration · v2026.4

« Moto oyo ayebi te kotombola miso na likolo, akoki te koyeba esika oyo mbula eutaka. » — Proverbe Sakata

SAKATA

© 2026 — Brume de la Rivière. Tous droits réservés.

CULTURE ECOLE LANGUE HISTOIRE FORUM