FR

Bienvenue sur Sakata

Ce portail est un sanctuaire numérique dédié à la préservation et à la transmission de l'identité culturelle du peuple **Sakata**.

Notre objectif est d'unir nos racines ancestrales avec la splendeur numérique moderne, en offrant à la fois des archives vivantes, des sagesses intemporelles et un forum d'échange intergénérationnel.

Suivant →

> *Un utilisateur cherche « rituels d'initiation à la maturité ». Aucun article ne contient cette phrase exacte. Mais l'article « Les passages — du jeune au Likonde » répond précisément. La recherche par mots-clés échoue ; la recherche sémantique trouve.*

DÉFINITION

Qu'est-ce que c'est ?

À chaque publication d'article, son contenu est **vectorisé** (transformé en un embedding de 3 072 dimensions par OpenAI), puis stocké dans un index Pinecone. Une requête utilisateur est elle-même vectorisée, et Pinecone retourne les K articles les plus proches dans l'espace sémantique.

DÉCISION

Pourquoi Pinecone et pas pgvector ?

CHOIX

Pinecone (service managé) plutôt que pgvector (extension Postgres dans Supabase).

CRITÈRE	PGVECTOR (SUPABASE)	PINECONE MANAGÉ	VERDICT
Coût	Gratuit (inclus)	70$/mois starter, gratuit < 5M vectors	pgvector
Performance < 10k vectors	Très bonne	Très bonne	Égal
Performance > 100k vectors	Acceptable	Excellente	Pinecone
Filtres metadata	SQL natif	API spécifique	pgvector pour le confort
Update sans downtime	OK	Excellent (versioning)	Pinecone
Pour Sakata aujourd'hui	—	—	Pinecone — pour la scalabilité Veillée

À 30 articles, pgvector ferait largement l'affaire. Mais avec 500 veillées prévues d'ici 1 an et chaque veillée pouvant produire 5-10 chunks, on parle de plusieurs milliers de vectors. Pinecone est prévu pour ce scaling.

PIPELINE

Architecture

Indexation à la publication

CODE TYPESCRIPT

```typescript
// À chaque article.status = "published"
async function indexArticle(article: Article) {
  // 1. Aplatir tout le contenu en texte
  const text = flattenBlocks(article.content.fr);

  // 2. Embedding via OpenAI
  const embedding = await openai.embeddings.create({
    model: "text-embedding-3-large",
    input: text.slice(0, 8000),  // Cap input
  });

  // 3. Upsert dans Pinecone
  await pinecone.index("sakata-articles").upsert([
    {
      id: article.id,
      values: embedding.data[0].embedding,
      metadata: {
        slug: article.slug,
        title: article.title.fr,
        category: article.category,
        published_at: article.published_at,
      },
    },
  ]);
}
```

Recherche

CODE TYPESCRIPT

```typescript
async function semanticSearch(query: string, k = 10) {
  const embedding = await openai.embeddings.create({
    model: "text-embedding-3-large",
    input: query,
  });

  const results = await pinecone.index("sakata-articles").query({
    vector: embedding.data[0].embedding,
    topK: k,
    includeMetadata: true,
  });

  return results.matches;
}
```

ROBUSTESSE

Fallback : recherche ilike traditionnelle

Si Pinecone est down, on dégrade vers une recherche `ilike` Postgres. Moins pertinente, mais toujours quelque chose. Implémentée dans `/api/articles/search`.

SÉCURITÉ

Sécurité — injection LIKE

BUG ÉVITÉ (AUDIT CACHE V2.3)

L'utilisateur peut envoyer `%` ou `_` dans sa requête, qui sont des wildcards LIKE. Sans échappement, on pourrait forcer la DB à scanner toute la table.

CODE TYPESCRIPT

```typescript
function escapeLike(s: string): string {
  return s.replace(/[%_\\]/g, "\\$&");
}

// Whitelist langue avant interpolation
const ALLOWED_LANGS = ["fr", "en", "skt", "lin", "swa", "tsh"] as const;
if (!ALLOWED_LANGS.includes(lang)) {
  return NextResponse.json({ error: "Invalid lang" }, { status: 400 });
}

// Toujours escaper avant LIKE
const safeQuery = `%${escapeLike(query)}%`;
const { data } = await supabase
  .from("articles")
  .select()
  .ilike(`title→${lang}`, safeQuery);
```

ÉVOLUTION

Recherche hybride — état actuel et futur

Aujourd'hui, recherche sémantique **OU** recherche textuelle. Idéal : combiner les deux (« hybrid search ») avec re-ranking par un modèle cross-encoder. Roadmap Q3 2026.

RETOUR D'EXPÉRIENCE

Difficultés rencontrées

Coût des embeddings

OpenAI `text-embedding-3-large` : 0.13$/M tokens. Un article de 2 000 mots ≈ 3 000 tokens ≈ 0.0004$. Soit 0.40$ pour 1 000 articles. Négligeable, mais à monitorer si la Veillée Numérique multiplie le volume par 100.

Pinecone latency aux États-Unis

Index hébergé en us-east-1 par défaut → latence ~200ms depuis Bruxelles, ~400ms depuis Kinshasa. Acceptable pour la recherche, douloureux pour l'autocomplete en temps réel.

À SAVOIR

Limitations connues

- Recherche sémantique non exposée dans l'UI publique aujourd'hui (à débloquer Q2 2026).
- Embeddings uniquement sur la version FR (pas par langue).
- Pas de re-ranking — le top 10 brut peut contenir du bruit.

Sakata.com — Documentation interne · feature-pinecone-search · v2026.4

« Moto oyo ayebi te kotombola miso na likolo, akoki te koyeba esika oyo mbula eutaka. » — Proverbe Sakata

SAKATA

© 2026 — Brume de la Rivière. Tous droits réservés.

CULTURE ECOLE LANGUE HISTOIRE FORUM