FR

Bienvenue sur Sakata

Ce portail est un sanctuaire numérique dédié à la préservation et à la transmission de l'identité culturelle du peuple **Sakata**.

Notre objectif est d'unir nos racines ancestrales avec la splendeur numérique moderne, en offrant à la fois des archives vivantes, des sagesses intemporelles et un forum d'échange intergénérationnel.

Suivant →

> *Il existe ~50 thèses, articles académiques et rapports ethnographiques publiés sur les Sakata, principalement entre 1950 et 1990. Beaucoup sont accessibles en PDF mais illisibles pour le grand public (jargon, structure académique). L'import automatisé peut les transformer en articles encyclopédiques en quelques heures, là où la rédaction manuelle prendrait des mois.*

POURQUOI

Le besoin

Sakata.com a aujourd'hui ~30 articles. Pour atteindre une masse critique SEO/utilisateur, il faut viser **300+ articles** en 3 mois. Trois approches possibles :

APPROCHE	VOLUME POTENTIEL	COÛT	QUALITÉ
Rédaction manuelle (auteurs)	5/semaine	200€/article	Excellente
Crowdsourcing diaspora	10-30/semaine	0€ + animation	Variable
Bulk import IA + validation	100/semaine	10€/article	Bonne après edit

CHOIX

Combiner les trois. Le bulk import donne le volume rapide pour la SEO, l'humain reste pour les articles signature.

PIPELINE

Stack technique

Étapes du pipeline

1. **Ingestion** — Upload PDF dans bucket `academic-sources`.
2. **Parsing** — Extraction texte via `pdf-parse` ou `pdfjs-dist`.
3. **Découpage** — Split en sections logiques (chapitres, sous-titres).
4. **Structuration IA** — Gemini 1.5 Pro convertit chaque section en blocs `ContentBlock`.
5. **Métadonnées IA** — Tags, catégorie, résumé, slug auto-généré.
6. **Citation source** — Auteur, année, ISBN/DOI ajoutés en bas d'article.
7. **File de validation** — État `imported`, admin valide ou rejette.
8. **Publication** — Une fois validé, status `published`.

PDF parsing — choix

LIB	POUR	CONTRE	VERDICT
pdf-parse (Node)	Simple, sync	Layout perdu (multi-colonnes mal géré)	🟡 OK pour textes simples
pdfjs-dist (Mozilla)	Vrai layout, positions	Plus complexe	✅ Pour PDFs académiques
Unstructured.io API	Excellent ML-based	Service tiers payant 0.01$/page	🟡 Si volume justifie
Tesseract OCR	Pour PDFs scannés	Lent, qualité variable	🟡 Backup pour vieux docs

CHOIX

`pdfjs-dist` par défaut, fallback Tesseract pour les scans. Unstructured.io si on dépasse 1 000 PDFs/mois (peu probable).

Prompt Gemini structuré

CODE TYPESCRIPT

```typescript
const STRUCTURING_PROMPT = `
Tu es un éditeur encyclopédique pour Sakata.com, plateforme du patrimoine
culturel Sakata (RDC). Voici un extrait d'un texte académique :

---
${textChunk}
---

Convertis ce texte en article web grand public en respectant ces règles :
1. Garder TOUS les faits, dates, noms propres
2. Reformuler le jargon académique en langage clair
3. Préserver les marqueurs culturels (Ngongo, Mboka, Likonde sans traduire)
4. Découper en blocs : { type: "heading"|"text"|"quote", body: string }
5. Maximum 8 blocs

Retourne du JSON strictement conforme au schéma ContentBlock[].
`;

const result = await gemini.generateContent({
  contents: [{ role: "user", parts: [{ text: STRUCTURING_PROMPT }] }],
  generationConfig: {
    responseMimeType: "application/json",
    responseSchema: ContentBlocksSchema,  // Garantie de validité
  },
});
```

QUALITÉ

Queue de validation humaine

NON NÉGOCIABLE

Aucun article généré par IA n'est publié sans validation humaine. Sakata.com n'est pas un slop SEO — c'est une référence culturelle.

Interface admin

- Page `/admin/imports` : liste des articles en attente avec source PDF associée.
- Diff side-by-side : extrait original PDF vs. article généré.
- Actions : approuver, rejeter, éditer puis approuver.
- Métadata édition : tags, catégorie, premium ou pas.

Critères d'acceptation

- Aucune erreur factuelle vs. PDF source.
- Cohérence ton avec le reste de Sakata.com (sage-basakata).
- Source clairement citée en bas d'article.
- Si > 30% à reformuler : rejet et re-prompting.

ROADMAP

Plan d'exécution — 3 sprints

Sprint 1 — Pipeline tech (1 semaine)

1. Bucket Storage `academic-sources` + RLS admin.
2. Edge function `process-pdf-import` avec pipeline complet.
3. Migration table `article_imports` (état + lien source).
4. Tests sur 3 PDFs représentatifs.

Sprint 2 — Interface validation (1 semaine)

1. UI `/admin/imports` avec liste, filtres, queue.
2. Diff viewer side-by-side (PDF embed + article structuré).
3. Actions approve/reject/edit avec workflow complet.

Sprint 3 — Bulk run (1 semaine)

1. Import des 50 PDFs académiques accumulés.
2. Validation manuelle quotidienne (10/jour pendant la semaine).
3. Mesure qualité : % articles approuvés vs rejetés.
4. Itération sur le prompt si < 70% acceptation.

BUDGET

Coût estimé

SOURCE DE COÛT	VOLUME	COÛT
Gemini structuration	300 articles × 8 chunks × 0.02$	≈ 50€
Pinecone embeddings	300 × 0.001$	≈ 0.30€
Storage PDFs (bucket)	50 PDFs × 5 MB	Inclus plan actuel
Temps validation humain	300 articles × 5 min	25h × 30€/h = 750€
Total	—	≈ 800€ pour 300 articles

COMPARAISON

Rédaction manuelle équivalente : 300 × 200€ = **60 000€**. Bulk import : **800€**. Soit **75× moins cher** pour une qualité « bonne après edit ».

LUCIDITÉ

Risques & mitigations

RISQUE	PROBABILITÉ	IMPACT	MITIGATION
Hallucinations (faits inventés)	Moyenne	Très haut	Validation humaine + prompt strict (« n'invente jamais »)
Sources sous copyright	Élevée	Haut	Whitelist de sources : domaine public, OA, autorisation explicite
Ton trop académique	Moyenne	Moyen	Few-shot examples dans le prompt (montrer 3 articles existants)
Slop SEO si trop de volume	Moyenne	Très haut	Plafond 100 articles/mois, mix avec contenu original

KPIS

Métriques de succès

- **Sprint 3 :** 50 articles validés, taux acceptation > 70%.
- **3 mois :** 300 articles publiés, trafic organique × 5.
- **6 mois :** Ratio 70% bulk-import / 30% rédigé manuellement, qualité maintenue.

Sakata.com — Documentation interne · roadmap-bulk-import-ethnographique · v2026.4

« Moto oyo ayebi te kotombola miso na likolo, akoki te koyeba esika oyo mbula eutaka. » — Proverbe Sakata

SAKATA

© 2026 — Brume de la Rivière. Tous droits réservés.

CULTURE ECOLE LANGUE HISTOIRE FORUM